YZM0206

Laboratuvar 7

KNN (K-Nearest Neighbors) ile

Musteri Segmentasyonu

Yusuf Ayberk Hekim

24458667025

14.05.2026

1. Giris ve Amac

Bu laboratuvar calismasinda, bir telekomunikasyon sirketinin 1000 musterisine ait demografik veriler kullanilarak KNN (K-En Yakin Komsu) algoritmasi ile musteri kategorisi tahmini yapilmistir. Hedef degisken olan custcat kolonu 4 farkli musteri segmentini temsil etmektedir.

Kod	Kategori	Aciklama
1	Basic Service	Temel hizmet
2	E-Service	Elektronik hizmet
3	Plus Service	Arti hizmet
4	Total Service	Tam hizmet

Calismada farkli K degerleri ve uzaklik olculeri denenerek en iyi model konfigurasyonu belirlenmistir.

2. Veri Seti Incelemesi (Kesifsel Analiz)

Veri seti toplam 1000 satir ve 12 kolon icermektedir. 11 bagimsiz degisken (region, tenure, age, marital, address, income, ed, employ, retire, gender, reside) ve 1 bagimli degisken (custcat) bulunmaktadir.

2.1 Temel Istatistikler

Ozellik	Ortalama	Std	Min	Max
tenure (ay)	35.53	21.36	1	72
age (yas)	41.68	12.56	18	77
income (gelir)	77.54	68.83	9	1668
employ (istihdam)	11.99	10.84	0	47

2.2 Sinif Dagilimi

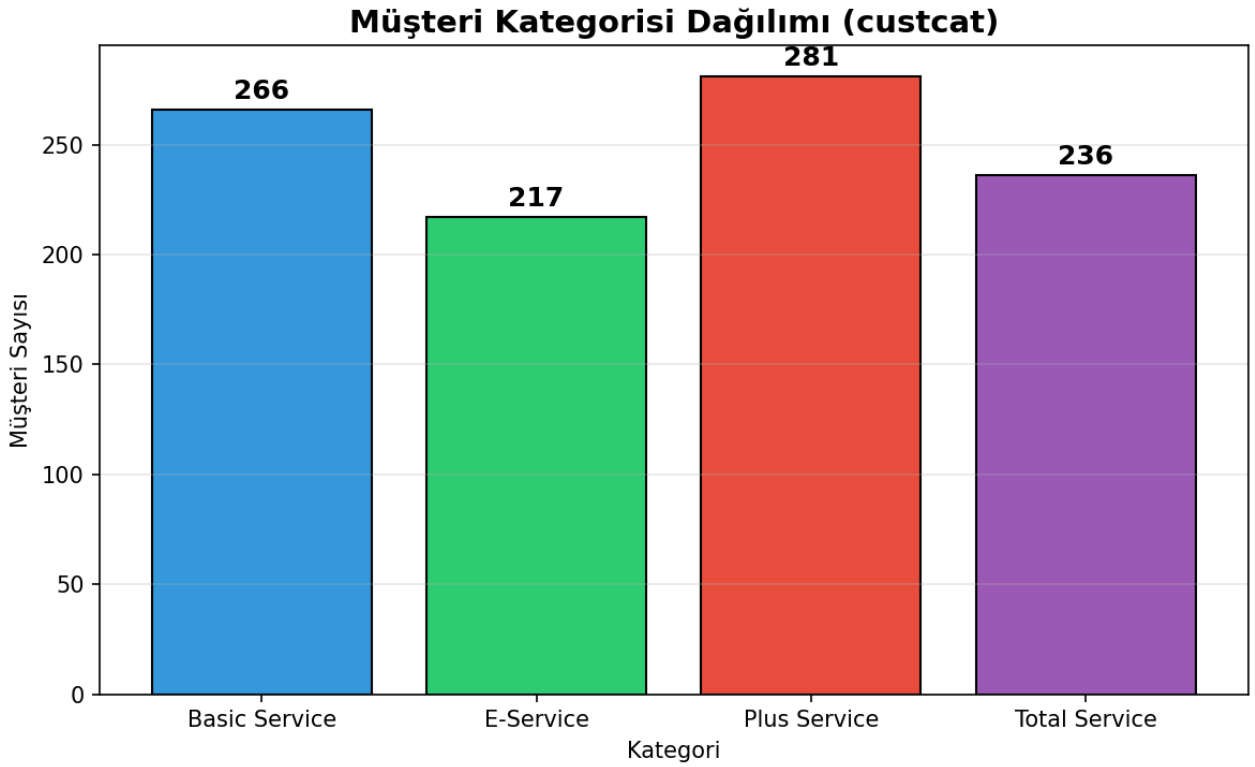

Sekil 1: Musteri Kategorisi Dagilimi

Sinif	Musteri Sayisi	Oran
Basic Service (1)	266	%26.6
E-Service (2)	217	%21.7
Plus Service (3)	281	%28.1
Total Service (4)	236	%23.6

Grafikten de gorulebilecegi gibi siniflar arasinda cok buyuk bir fark yok. Plus Service en kalabalik sinif (%28.1), E-Service ise en az musteriye sahip (%21.7). Aradaki fark %6 civari oldugu icin veri setimizi dengeli sayabiliriz. Bu da demek oluyor ki model kurarken herhangi bir sinifin ezilmesi gibi bir sorunla karsilasmayiz.

3. Veri On Isleme

3.1 Bagimsiz/Bagimli Degisken Ayirimi

X (Bagimsiz): 11 ozellik - numpy array (shape: 1000x11)
y (Bagimli): custcat kolonu - numpy array (shape: 1000,)

3.2 Normalizasyon (StandardScaler)

KNN algoritmasi mesafe tabanli calistigindan, farkli olceklerdeki ozellikler sonucu dogrudan etkiler. Ornegin, income kolonu 9-1668 arasinda deger alirken, gender yalnizca 0-1 arasindadir. Normalizasyon yapilmadiginda income kolonu mesafe hesaplamalarina baskin cikacak ve diger ozelliklerin etkisi ihmal edilecektir.

StandardScaler uygulanarak tum ozellikler ortalamasi 0, standart sapmasi 1 olacak sekilde donusturulmustur.

Ornek (ilk satir):
Normalizasyon oncesi: [2.0, 13.0, 44.0, 1.0, 9.0]
Normalizasyon sonrasi: [-0.03, -1.06, 0.18, 1.01, -0.25]

3.3 Train/Test Bolme

Veri seti %80 egitim (800 ornek) ve %20 test (200 ornek) olarak ayrilmistir. stratify=y parametresi ile sinif dagiliminin her iki kumede de korunmasi saglanmistir.

4. KNN Modeli - K=4

Ilk model n_neighbors=4 parametresiyle egitilmistir.

Metrik	Deger
Accuracy	0.3450 (%34.5)
F1-Score (weighted)	0.3446

Classification Report (K=4)

Sinif	Precision	Recall	F1-Score	Support
Basic Service	0.30	0.40	0.34	53
E-Service	0.36	0.34	0.35	44
Plus Service	0.34	0.36	0.35	56
Total Service	0.42	0.28	0.33	47

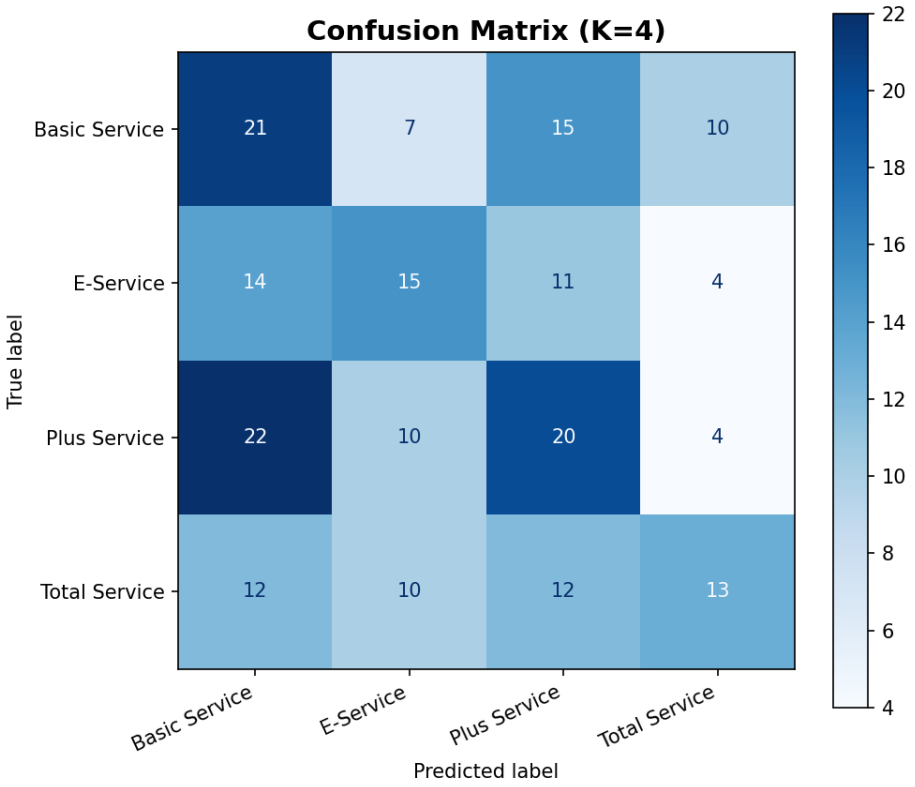

Sekil 2: Confusion Matrix (K=4)

K=4 ile %34.5 dogruluk elde ettik. 4 sinifli bir problemde rastgele tahmin %25 civarinda olurdu, dolayisiyla model rastgeleden iyi ama cok da tatmin edici degil. Ozellikle Total Service sinifinda recall 0.28 cikti, yani bu kategorideki musterilerin cogu yanlis tahmin ediliyor.

5. KNN Modeli - K=6 ve Karsilastirma

Sinif	Precision	Recall	F1-Score	Support
Basic Service	0.37	0.47	0.42	53
E-Service	0.40	0.41	0.40	44
Plus Service	0.42	0.45	0.43	56
Total Service	0.41	0.26	0.32	47

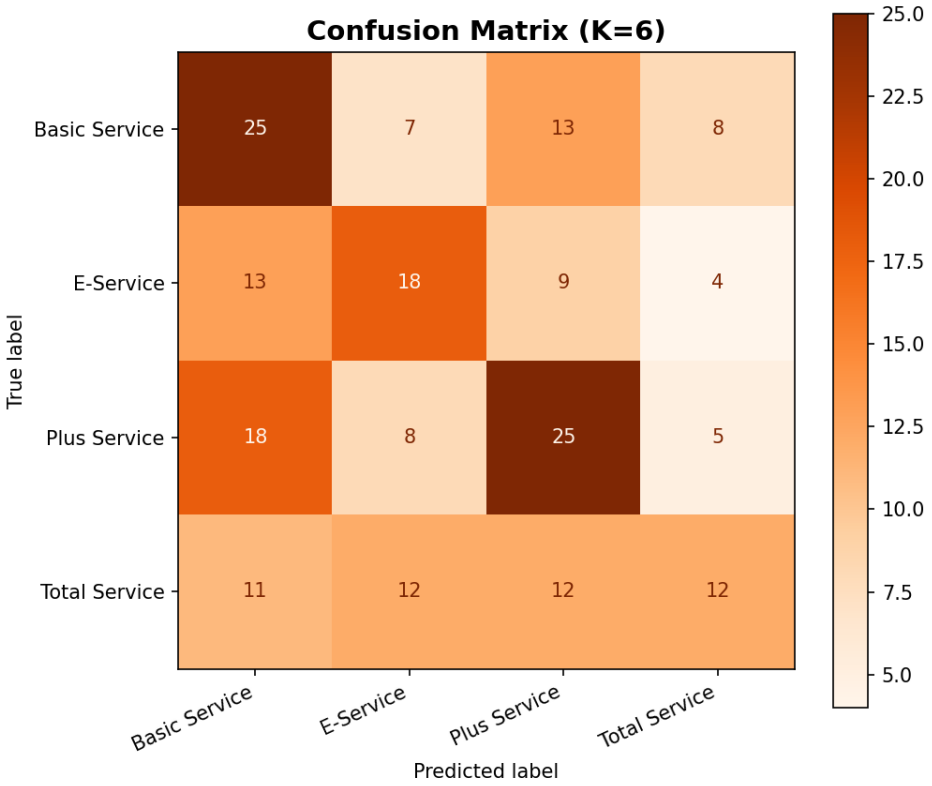

Sekil 3: Confusion Matrix (K=6)

K=4 vs K=6 Karsilastirmasi

Metrik	K=4	K=6	Fark
Accuracy	0.3450	0.4000	+5.5%
F1-Score	0.3446	0.3954	+5.1%

K=6 sectigimizde accuracy %40'a cikti, yani K=4'e gore %5.5'lik bir artis oldu. K'yi artirmak modelin daha az ezberlemesini ve daha genel karar vermesini sagladi. Yine de Total Service sinifinda hala zorluk var, recall 0.26 ile oldukca dusuk kaldi.

6. Optimum K Degerinin Belirlenmesi

K=1'den K=20'ye kadar her deger icin model egitilip test edilmistir:

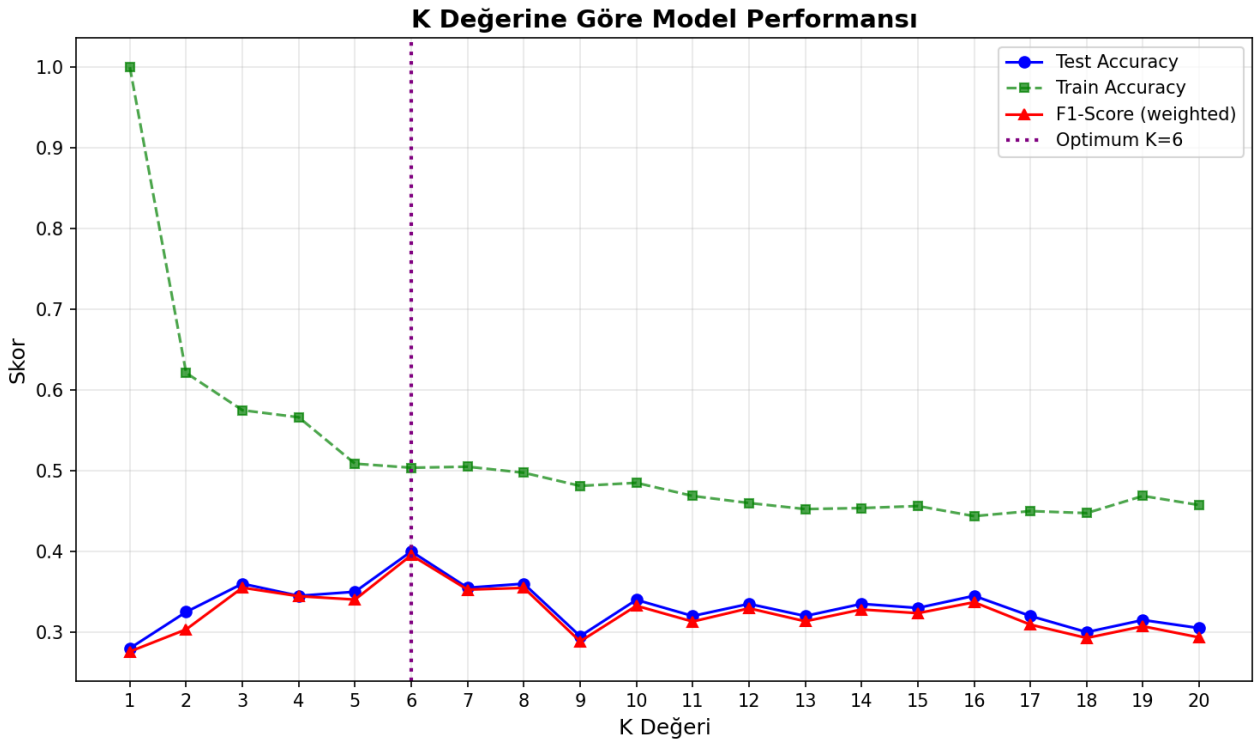

Sekil 4: K Degerine Gore Model Performansi

K	Test Acc	Train Acc	F1-Score
1	0.2800	1.0000	0.2759
2	0.3250	0.6212	0.3034
3	0.3600	0.5750	0.3551
4	0.3450	0.5663	0.3446
5	0.3500	0.5088	0.3403
6 (Optimum)	0.4000	0.5038	0.3954
7	0.3550	0.5050	0.3526
8	0.3600	0.4975	0.3549
9	0.2950	0.4813	0.2885
10	0.3400	0.4850	0.3327

Overfitting Analizi

Grafikte K=1'de dikkat cekici bir durum var: train accuracy %100 ama test accuracy %28. Bu tam anlamiyla overfitting. Model egitim verisini ezberledi ama yeni veri gordugunde basarisiz oldu.

K buyudukce iki egri birbirine yaklasti, yani model daha dengeli hale geldi. Ama K'yi cok artirinca da (mesela K=20'de) test accuracy %30.5'e dustu cunku artik model cok genel kaliyor, detaylari yakalayamiyor.

7. Farkli Uzaklik Olculeri Karsilastirmasi

Optimum K=6 degeriyle farkli mesafe metrikleri denenmistir:

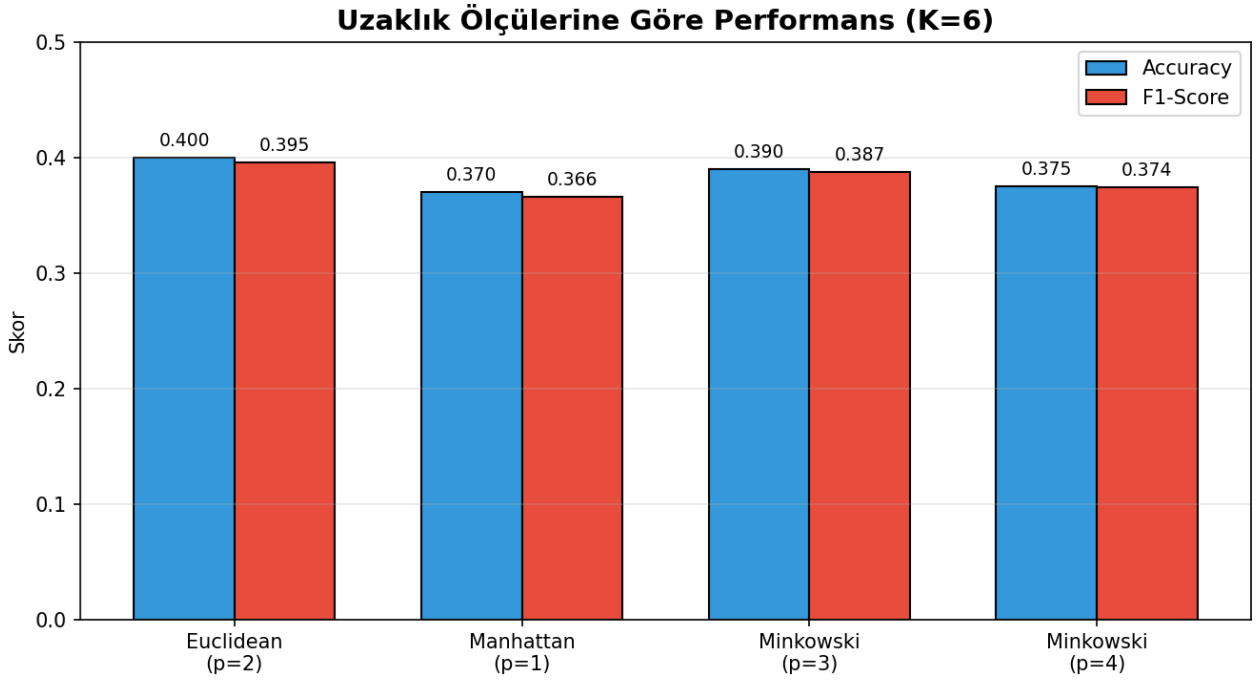

Sekil 5: Uzaklik Olculerine Gore Performans

Uzaklik Olcusu	p degeri	Accuracy	F1-Score
Euclidean	p=2	0.4000	0.3954
Manhattan	p=1	0.3700	0.3661
Minkowski (p=3)	p=3	0.3900	0.3875
Minkowski (p=4)	p=4	0.3750	0.3739

Uzaklik Formulleri:
- Euclidean (p=2): d = sqrt(sum((xi - yi)^2))
- Manhattan (p=1): d = sum(|xi - yi|)
- Minkowski: d = (sum(|xi - yi|^p))^(1/p)

Euclidean en iyi sonucu verdi. Manhattan her boyuttaki farki esit agirlikta alirken, Euclidean buyuk farklari daha cok onemsedi. Bu veri setinde Euclidean'in daha iyi calistigi ortaya cikti. Aradaki farklar cok buyuk olmasa da Euclidean tutarli sekilde one cikti.

8. Final Modeli - En Iyi Konfigurasyon

Parametre	Deger
Algoritma	KNN
K (komsu sayisi)	6
Uzaklik olcusu	Euclidean (p=2)
Normalizasyon	StandardScaler

Train/Test orani	80/20

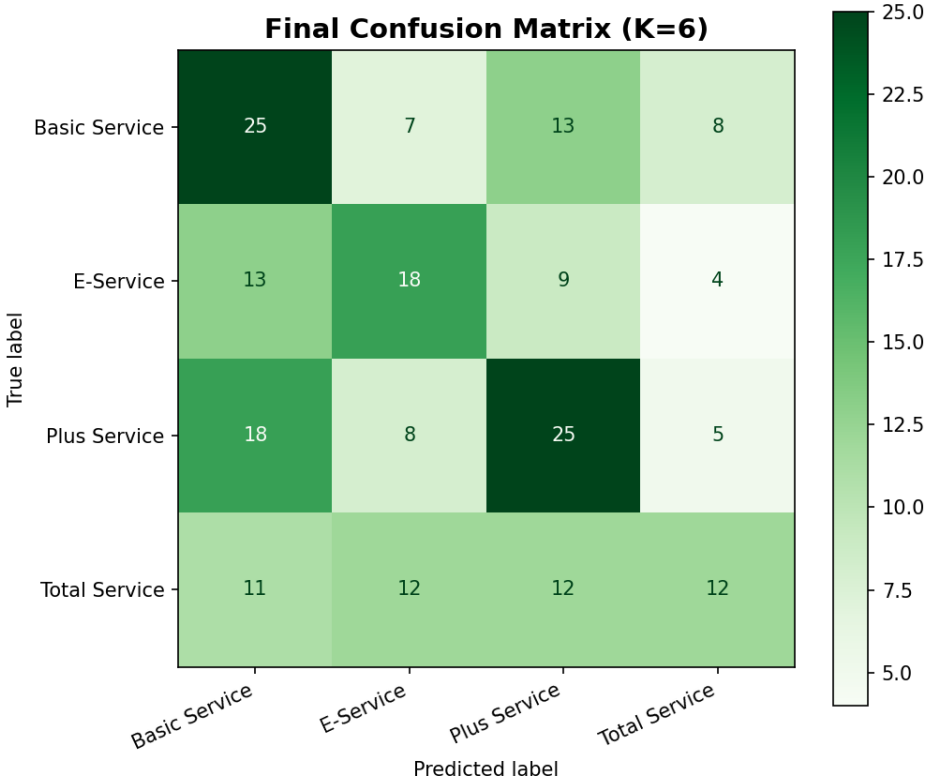

Sekil 6: Final Confusion Matrix (K=6)

9. Sonuc ve Degerlendirme

Bu calismada KNN algoritmasi ile telekom musterilerini 4 kategoriye ayirmaya calistik. Ilk olarak veri setindeki sinif dagilimina baktigimizda, siniflar arasinda cok buyuk farklar olmadigini gorduk. En kalabalik sinif Plus Service (%28.1), en az olan ise E-Service (%21.7). Aradaki fark %6 civari, yani veri seti bu acisindan model kurmaya uygun gorunuyor.

Normalizasyon konusunda su durumu fark ettik: income degerleri 9'dan 1668'e kadar cikan bir aralikta iken gender sadece 0 ya da 1 degeri aliyor. Eger normalizasyon yapmasaydik KNN mesafe hesaplarken income'u diger her seyin onune koyacakti. Bu yuzden StandardScaler ile tum degiskenleri ayni olcege getirdik.

K degerini belirlemek aslinda bu labin en onemli kismiydi. K=4 ile basladigimizda %34.5 accuracy aldik, K=6'ya cikinca bu %40'a yukseldi. Sonra 1'den 20'ye kadar tum K degerlerini denedik. K=1'de ilginc bir sey oldu: train accuracy %100 ama test accuracy sadece %28. Yani model egitim verisini tamamen ezberledi ama yeni veri gordugunde basarisiz oldu. Derste bahsedilen overfitting durumunun tam da kendisi bu.

K arttikca train ve test accuracy arasindaki fark kapaniyor ama bir yerden sonra da model cok genel kaliyor. K=6 bu ikisi arasindaki en iyi dengeyi sagladigi icin optimum K degeri olarak K=6'yi sectik. F1-Score acisindan da en yuksek degeri (0.3954) K=6 verdi.

Uzaklik olculerini de denedik. Euclidean, Manhattan ve Minkowski'nin farkli p degerleriyle karsilastirma yaptik. Euclidean (p=2) en iyi sonucu verdi. Bunun sebebi buyuk ihtimalle Euclidean'in buyuk farklara daha fazla agirlik vermesi ve bu veri setinin yapisina daha uygun olmasi.

Sonuc olarak en iyi modelimiz K=6 ve Euclidean mesafesi ile %40 accuracy elde etti. Bu deger acikcasi cok yuksek degil. 4 sinifli bir problemde rastgele tahmin %25 verir, biz bunun biraz ustundeyiz. Bence bunun sebebi elimizdeki ozelliklerin musteri kategorisini tam olarak ayirt etmeye yetmemesi. Belki daha farkli ozellikler eklenseydi ya da Random Forest veya SVM gibi farkli algoritmalar kullansaydik daha iyi sonuc alinabilirdi.

F1-Score Hakkinda

Derste de gorudugumuz gibi F1-Score, Precision ve Recall degerlerinin harmonik ortalamasidir. Cok sinifli problemlerde sadece accuracy'ye bakmak yaniltici olabiliyor. Mesela model hep ayni sinifi tahmin etse bile accuracy yuksek cikabilir ama bu gercek bir basari olmaz. F1-Score her sinifin ne kadar dogru tahmin edildigini daha adaletli olcuyor.

Formul: F1 = 2 x (Precision x Recall) / (Precision + Recall)